



西南财经大学
SOUTHWESTERN UNIVERSITY OF FINANCE AND ECONOMICS

西南财经大学 课程论文

论文题目： 基于深度学习的企业融资成本研究
——以企业竞品关系为视角

学生姓名： _____

论文类型： _____

所在学院： _____

专 业： _____

学 号： _____

指导教师： _____

成 绩： _____

年 月

西南财经大学

本科毕业论文原创性及知识产权声明

本人郑重声明：所呈交的毕业论文是本人在导师的指导下取得的成果，论文写作严格遵循学术规范。对本论文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。因本毕业论文引起的法律结果完全由本人承担。

本毕业论文成果归西南财经大学所有。

特此声明

毕业论文作者签名：

作者专业：

作者学号：

2023 年 3 月 2 日

摘要

二十大中，国务院在关于金融工作情况的报告指出，需要坚持稳中求进工作总基调，实现经济的高质量发展。而降低企业的融资成本是间接促进经济高质量发展的必然要求，因此，对融资成本的研究至关重要。近年来，随着中国经济的快速发展，企业间竞争日益激烈，竞争对融资成本的影响也越来越明显，因此，在研究企业的融资成本时，考虑产品的市场竞争关系是很有必要的。然而，目前基于市场竞争关系对融资成本的研究，大多是将静态的衡量竞争的指标纳入计量模型，并未充分考虑企业相互竞争的复杂拓扑关系。

随着图神经网络技术的发展，非欧式数据的研究进入一个新阶段，因此，在本研究中，我们采用图神经网络建模企业产品竞争关系，以充分考虑相互竞争的复杂拓扑关系。具体而言，本研究提出的融资成本预测模型由两个子任务组成。首先，我们通过企业年报数据，初步提炼企业产品竞争关系网络，由于年报数据具有不完整性，提取出的竞品关系网络也会存在信息缺失，因此，我们采用强化学习方法建模链路预测任务，对竞品关系网络中可能缺失的链路进行补全；第二个子任务是利用补全的竞品关系网络，将历史融资成本数据作为节点特征，进行未来年度的融资成本的预测，在该子任务中，我们在图神经网络中引入了分级注意力机制，对直接竞争关系的企业和间接竞争关系的企业给予不同的注意力。

我们在 2010-2021 年中国 A 股上市公司的数据中进行了实验，由于未来一年期的融资成本也许与当年融资成本相差不会太大，因此我们建立了三个模型，分别预测未来 1-3 年度的融资成本，以期探索在长期状态中，竞品关系对企业融资成本的影响。实验结果表明，补全后的竞品关系网络，在未来 1-3 年度的预测任务中，都表现出了显著优势；此外，我们所提出的分级注意力机制，能够对 GCN、GraphSAGE 模型有显著的效果提升。

关键词：竞品关系；强化学习；链路预测；图神经网络；融资成本

Abstract

At the 20th National Congress of the Communist Party of China, the State Council pointed out in its report on financial work that it is necessary to adhere to the general tone of seeking progress while maintaining stability and achieve high-quality economic development. Reducing the financing cost of enterprises is an inevitable requirement for indirectly promoting high-quality economic development. In recent years, with the rapid development of China's economy, the competition among enterprises has become increasingly fierce, and the impact of competition on financing costs has become more and more obvious. Therefore, it is necessary to consider the market competition relationship of products when studying the financing cost of enterprises. However, most of the current researches on financing costs based on market competition relations incorporate static indicators of competition into the measurement model, and do not fully consider the complex topological relationship of enterprises' competition.

With the development of graph neural network, the research on non-European data has also entered a new stage. Therefore, in this study, we use the graph neural network method to model the competitive relationship of enterprise products to fully consider the complex topological relationship of competition. Specifically, the financing cost prediction model proposed in this study consists of two sub-tasks. First of all, we preliminarily refine the enterprise product competition relationship network through the enterprise annual report data. Due to the incompleteness of the annual report data, the extracted competitive product relationship network will also have information loss. Therefore, we use the reinforcement learning method to model the link prediction task and complete the possible missing links in the competitive product relationship network. The second sub-task is to use the completed competitive relationship network to predict the financing cost of the next year by using the historical financing cost data as the node feature. In this

sub-task, we introduce a hierarchical attention mechanism in the graph neural network, which gives different attention to enterprises with direct competition and enterprises with indirect competition. This hierarchical attention mechanism can be effectively embedded in different graph neural network structures, such as GCN, GraphSAGE, etc.

We conducted experiments in the data of China's A-share listed companies from 2010 to 2021. Since the financing cost of the next year may not be much different from that of the current year, we have established three models to predict the financing cost of the next 1-3 years respectively, with a view to exploring the impact of competitive relationship on the financing cost of enterprises in the long term. The experimental results show that the completed competitive product relationship network shows significant advantages in the prediction tasks in the next 1-3 years; In addition, our hierarchical attention mechanism can significantly improve the GCN and GraphSAGE models.

Keywords: Competitive relationship; reinforcement learning; link prediction; graph neural network; financing cost

目录

摘要	1
Abstract	1
1. 绪论	1
1.1. 研究背景	1
1.2. 研究意义	2
1.2.1. 理论意义	2
1.2.2. 现实意义	2
1.3. 研究内容与行文安排	3
1.3.1. 研究内容	3
1.3.2. 行文安排	3
2. 国内外研究进展	5
2.1. 产品市场竞争与债务融资成本	5
2.2. 链路预测	6
2.3. 分级注意力机制的图神经网络	8
3. 理论背景	11
3.1. 图神经网络	11
3.1.1. 图的基本概念	11
3.1.2. 图卷积网络 (Graph Convolution Networks, GCN)	12
3.1.3. GraphSAGE	14
3.1.4. 图注意力网络 (Graph Attention Networks)	18
3.2. 深度强化学习	20

3.2.1. 强化学习概述	20
3.2.2. 强化学习原理	21
3.2.3. 深度强化学习	23
3.2.4. PPO 算法	24
4. 模型构建	27
4.1. 模型整体框架	27
4.2. 竞品关系补全	27
4.3. 融资成本预测模型	29
4.3.1. 问题定义	29
4.3.2. 模型架构	30
4.3.3. 损失函数	31
4.3.4. 评价指标	31
5. 实验设计及结果分析	33
5.1. 数据集	33
5.2. 竞品关系补全	35
5.3. 融资成本预测	35
5.3.1. 结果分析	36
5.3.2. 消融实验	38
6. 总结与展望	39
7. 致谢	49

1. 绪论

1.1. 研究背景

近年来，面对百年变局和世纪疫情相互叠加的复杂环境，我国金融系统持续向前发力，坚决稳住经济大盘，有效防范金融风险，实现了社会经济发展的稳定态势和较强韧性。二十大中，国务院在关于金融工作情况的报告指出，需要坚持稳中求进工作总基调，实现经济的高质量发展。而降低企业的融资成本，是间接促进经济高质量发展的应有之义和必然要求^[19]，融资成本的高低影响着企业的持续经营和发展能力，也影响着企业的投融资决策。

当前，在企业债务融资方面的研究而言，学者们从不同的角度研究了债务融资成本的影响因素，一些学者^[3,16,27,47]探讨了证券公司 ESG 发展对融资成本的影响，王俊^[14]等学者认为卖空制度有助于抑制企业的过度融资，提高企业资源配置效率，罗莉苹^[17]、刘梦莎^[6]、向志容^[7]、刘中华^[4]、万国超^[1]等学者分别从股东治理、数字化转型、LPR 机制改革、司法改善、股价崩盘风险的角度研究了债务融资成本的影响因素。

近年来，随着中国经济的快速发展，消费者对产品的需求量增加，内外资企业蓬勃发展，企业之间的竞争也越来越激烈。一方面，产品市场竞争的固有经营风险可以直接导致企业债务融资成本的提高，另一方面，产品市场竞争可通过影响产品市场势力、企业社会责任、企业战略差异等多个不同的因素，间接影响企业债务融资成本。因此，从企业产品竞争关系的视角来研究融资成本，具有重要的价值。然而，目前基于市场竞争关系对融资成本的研究，大多是将静态的衡量竞争的指标纳入计量模型，并未充分考虑企业相互竞争的复杂拓扑关系。

目前，随着深度学习技术的发展，深度学习在金融市场预测、金融风险管理、金融欺诈检测、金融机构客户分析等研究领域取得了良好的进展，尤其是近几年图神经网络技术的发展，对非欧式数据的研究也进入了一个新阶段，因此，在本

研究中，我们采用图神经网络的方法来建模企业产品竞争关系，以充分考虑相互竞争的复杂拓扑关系。此外，现有的融资成本预测研究大多是对未来一年期的融资成本进行预测，然而，除非是企业该年度有重大战略决策的变化，否则，当期融资成本是与下一期融资成本相差不大的，因此，在实际应用层面，仅预测未来一年期的融资成本，对企业的实际价值不大。因此，本研究对企业未来 1-3 年度的融资成本进行预测。

基于此，本研究提出了一种新的融资成本预测框架，以沪深 A 股上市公司为研究对象，以各公司主营业务产品的竞争关系为视角，以深度学习中的图神经网络为主要技术手段，利用企业过去三年的融资成本数据，对企业未来 1-3 年度的融资成本进行研究，以期为企业未来年度的投融资计划提供一定的参考。

1.2. 研究意义

1.2.1. 理论意义

1. 为融资成本预测提供新技术手段：本文采用深度学习中的图神经网络算法，利用已构建好的企业竞品关系网络，对企业融资成本进行预测。虽然已有学者研究竞品关系对债务融资成本的影响，但较少学者考虑企业产品竞争关系中的复杂结构。因此，本研究从理论上为融资成本预测提供新技术手段，丰富了融资成本的研究。同时，竞品关系网络的引入，也为融资成本的研究提供了一种新的视角。

2. 为企业竞品关系构建提供新思路：本研究通过构建企业竞品关系网络，并采用强化学习方法进行链路预测，以补全网络中可能缺失的竞争关系，以此构建更完善、关系更强的竞品关系网络。因此，本研究从理论上丰富了企业竞品关系构建的思路。

1.2.2. 现实意义

本文充分利用企业竞品关系以及企业过往的债务融资成本信息，来对企业未来的 1-3 年度的债务融资成本进行预测，希望企业能根据模型结果，分析自身所处行业的竞争程度来制定各项经营策略，以防范高竞争程度造成债务融资成本的提

高等风险。因此，本研究在帮助企业进行融资成本管控以及风险管控方面具有一定的现实意义。

1.3. 研究内容与行文安排

1.3.1. 研究内容

本文以上市公司主营产品中存在的竞争关系为视角，提出了一种新的债务融资成本预测框架，该框架可分为两个子任务：

1) 竞品关系补全：首先，我们根据上市公司年报中的经营范围、经营产品初步提炼企业竞争关系网络，再使用强化学习方法，对竞品关系网络中可能缺失的竞争关系进行补全，以生成竞争关系更加完整的企业竞品关系网络。

2) 融资成本预测：由于对某一特定的公司而言，具备直接竞争关系的公司和具备间接竞争关系的公司对其融资成本的影响不同，因此我们采用基于分层注意力的图神经网络，利用过去三年的融资成本信息，对企业未来 1-3 年度的融资成本进行预测。

1.3.2. 行文安排

本文的行文安排如下：

第一章：绪论。说明本文的研究背景和研究意义，大致阐述本文的研究内容以及主要用到的方法，同时梳理本文的研究框架。

第二章：国内外研究进展。该部分说明本文涉及到的相关研究方向的国内外研究综述，首先梳理了融资成本研究的相关文献，并重点总结了已有研究中关于市场竞争对融资成本产生影响的相关文献证据。随后，根据本研究中涉及到的竞品关系网络补全、融资成本预测，分别对链路预测、节点预测任务相关的文献进行了梳理。

第三章：理论背景。阐述了本文所涉及到的算法的理论基础，分别为图神经网络和深度强化学习。

第四章：模型构建。描述了本文所提出的债务融资成本预测框架的具体建模，

分竞品关系补全和融资成本预测两个子任务来描述。

第五章：实验设计及结果分析。针对竞品关系补全、融资成本预测进行了一系列对比、消融实验，并对结果进行了分析。

第六章：总结与展望。根据前几章的结果得出相应的结论，结合实际情况对结果进行理论分析，最后对未来可进一步发展的研究方法做出展望。

2. 国内外研究进展

2.1. 产品市场竞争与债务融资成本

产品市场竞争对债务融资成本的影响，可分为直接影响和间接影响。首先，产品市场竞争的固有经营风险，可以直接导致企业债务融资成本的提高。1966 年，Telser^[50]提出债务融资的“深口袋”理论，即由于存在外部融资约束，公司的财务杠杆越高，当其处于市场竞争不利地位时，越有可能受到竞争对手的掠夺性攻击，公司就越有可能走向破产。不难发现，该理论放弃了不存在外部融资约束的假设，与现实情况也更为贴合。产品市场竞争必然会引发价格战、营销战，进而会引起利润和经营现金流入下降，在这样的情况下，财务杠杆高的企业首当其冲，不仅会面临或多或少的财务危机，紧张事态的蔓延更会引起客户、供应商、债权人等利益相关者对企业的一系列的连锁反应，势必会造成企业财务状况的雪上加霜。简而言之，激烈的市场竞争会引起销售下降，现金流入减少，压榨内源融资空间，减少外源融资渠道，最终导致企业退出市场^[45]。国内学者朱武祥等^[11]以燕京啤酒为例进行案例研究，提出当公司预期未来市场竞争激烈时，当前会选择较低的债务规模，采取保守的融资策略。

另一方面，在企业债务融资中，产品市场竞争通过影响多个不同的因素，间接影响着债务融资成本。比如，Yao et al.^[55]以 2016-2020 年中国上市公司数据为样本，实证考察了企业社会责任、债务融资成本与企业创新之间的关系，探讨了市场竞争的调节作用。并认为，市场竞争激烈时，企业可以获得更多的回报来履行社会责任，更有效地降低债务融资成本，当市场竞争程度较低时，企业降低债务融资成本的需求较低，因为此时通常表明行业存在垄断企业，此类企业具有更加丰富的创新资源，其他企业即使通过社会责任降低融资成本，也很难通过创新获得核心竞争力。戴书松等学者^[9]分析了产品市场势力、市场竞争与债券融资成本之间的关系，首先，产品市场势力越强，债券融资成本越低，而市场竞争可作为

产品市场势力与债券融资成本之间的调节因素，即市场竞争可以加剧产品市场势力与债券融资成本的负向关系。施静^[10]采用多元线性回归模型，以零售行业为例，分析了行业产品竞争与战略差异对债务融资成本的影响。行业竞争程度越高，企业间的战略差异能够更加显著地降低零售企业的债务融资成本。

此外，市场竞争本身作为一种外部监督机制，能实现对企业管理者很好的监督作用，能降低企业管理者采取机会主义的可能性，改善企业管理者与债权人之间的信息不对称程度，进而影响债务融资成本。伊志宏等^[2]认为公司治理结构的合理安排，能够促使企业披露更加完善、更加高质的信息，而产品市场竞争则对某些公司治理机制产生了互补或替代的作用。姜付秀等^[8]，黎来芳等^[20]当处在一个更为激烈的产品市场竞争中时，企业内部由于委托代理问题所产生利益冲突的利益相关者更容易为降本增效达成一致看法。产品市场竞争由此降低了企业的代理成本、提升了代理效率，同时在这种情况下也会提高企业的投资效率，抑制企业的非效率投资。同时也有学者发现，激烈的产品市场竞争同样也会促进公司治理机制的合理安排以及公司治理机制有效性的发挥，例如刘凤委等^[5]发现央企控股的上市公司所处的行业竞争越激烈，EVA 抑制企业过度投资的作用也更为明显。而这种行业竞争对企业治理的优化促进作用，也会形成行业内的马太效应，致使整个行业表现出良好的整体特征，如行业内的企业资源错配程度显著降低^[15]等。

2.2. 链路预测

由于上市公司信息披露的不完整性，直接从年报数据中提取的企业产品竞争关系可能存在缺失，因此，为了提高融资成本预测的准确率，补全缺失的企业竞品关系是一项必要的任务，我们采用链路预测范式来完成这一任务，生成关系更加完善的增强图。链路预测是指，根据网络中已有的链路，去推断网络中缺失的链路或者预测未来可能会存在的网络。链路预测作为网络科学中的一个基本问题，具有巨大的现实应用^[53]。关于链路预测的相关研究，可分为基于特征提取的方法和基于特征学习的方法^[52]。

基于特征提取的方法是较为常见的链路预测方法。对于考虑局部相似性的链路预测，节点之间共同邻居节点的个数越多，则认为两个节点之间更有可能存在

链路^[62],但这种方法在较大的图或者稀疏图中,往往具有较低的精确度。全局的结构相似性^[44]能解决这种问题,但往往会带来较大的计算开销。此外,还有基于概率的方法,这类方法通常假设已知图的先验结构,例如分层或者圆形的结构^[22],但概率方法的精度通常是不太高的。为了充分利用图中隐藏的结构信息,Moore 和 Newman^[22,28,39]提出了一种分层模型用于预测网络中缺失的链路,该模型在具有明显分层结构的网络中具有很好的性能,但在分层不明显的网络中表现较差。对于某些不适合分层模式的网络,基于似然估计的 Stochastic Block Models (SBM)^[33] 模型被提出。它的基本思想是根据网络模块化的特点对网络的节点进行分组,而两个节点是否与链路相连取决于它们的分组。SBM 模型可以预测缺失的链路,并根据可信度判断哪些是错误的链路。SBM 的平均表现优于分层模型。然而,它具有与分层模型相同的计算时间复杂度高的问题。

基于特征学习的算法通过学习节点特征的低维嵌入表示来进行链路预测。主要可分为基于图神经网络的算法和基于强化学习的算法。基于图神经网络的方法使用监督学习的形式,将链路预测建模为分类问题,Zhang et al.^[57]提出了一种 WLNM 算法,该算法提取目标链路周围的封闭子图,并将子图编码为向量表示,用于后续分类。多项研究^[23,38,49,51]采用自动编码器公式,使用 GNN 对节点表示进行编码,并将节点之间的边解码为节点对上的函数。zhang et al.^[58]提出了 SEAL 算法,首先根据节点到源节点和目标节点的距离来标记每个封闭子图中的节点,然后应用 DGCNN^[59]算法学习链路预测任务中的链路表示,这种方法被证明比自动编码器更强大^[60],但需要为每一个链路具体化一个子图,且难以扩展到较大的图中。Li et al.^[41]提出了一种类似于 SEAL 的节点标记技巧,这种技巧直接使用节点到目标节点的最短距离来标记节点。You et al. 提出了一种利用锚节点将节点的相对位置信息引入 GNN 的算法,被称作位置感知 GNN(P-GNN)。

强化学习算法通过智能体与环境的交互中的历史和经验做出决策。强化学习采用边获取样本边学习的方法,在获得样本后会更新自己的模型,并使用当前模型来指导下一步的动作,下一个动作获得结果后,更新模型并迭代,直到模型收敛。强化学习算法在链路预测任务中的应用主要包括图卷积策略网络算法 (GCPN) 和图转换策略网络算法 (GTPN)。You et al.^[56]在 2018 年提出了 GCPN 算法,该算法将图的生成过程建模为马尔可夫的决策过程,并采用生成模型作为运行在图

生成环境中的智能体。在 GCPN 算法中，智能体输出的动作即为要解决的链路预测问题，并使用 GCN 学习节点表示信息，从而通过策略梯度方法实现端到端的训练。对比实验发现，GCPN 在图生成问题上是有有效的，在链路预测上有优越的性能。Do et al.^[25] 提出了 GTPN 算法，GTPN 通过 GCN 实现对节点的表示学习，同时通过 RNN 来编码历史预测信息。在他们的研究中，GTPN 被用于预测化学反应产物，智能体通过选择分子图中的节点对并预测他们的新键类型。

2.3. 分级注意力机制的图神经网络

传统融资成本预测任务中使用的计量模型无法完全反映公司产品市场竞争之间的复杂关系。针对金融市场信息的非欧式特征，已有研究引入了图神经网络来学习金融信息间不同关系的分布表示。Chen et al.^[21] 根据市场投资事件构建公司关系网络，并通过图卷积神经网络捕获公司间的关系，以做出更准确的预测。Feng et al.^[26] 将行业和公司间的关系嵌入到 GNN 模型中，通过时间图卷积网络为股票定制排名系统。Yang et al.^[54] 提取供应链关系，将交互数据形成图，并进行贷款违约预测。Kudo et al.^[40] 为了检测电子商务平台上的欺诈性评论，使用符号图卷积网络方法构建了有向的符号评论图。Li et al.^[42] 使用股票价格的历史数据相关矩阵构建图标，以预测京东股票价格指数的走势。

随着实际的网络关系数据越来越复杂，研究人员意识到可能需要更加复杂的建模方法去探索图中不同类型的关系，因此，分层注意力机制被引入到图神经网络的模型中。例如，为了预测具有多视图数据的每个消费者的默认概率，Liang et al.^[43] 利用分层注意力机制对每个视图上的特征进行编码。在探索多重关系时，Hu et al.^[34] 提出了一种基于属性化的多重图模型，该模型引入了特定于关系的层和注意力机制，使模型能联合建模多个关系。Itoh et al.^[36] 提出了可获取局部和全局信息的多级注意力池化机制，对于图中的每一个信息传递层，都采用一个注意力池化层来计算逐层表示。Zhao et al.^[61] 提出了分级注意力和图神经网络相结合的方法，用于半结构化文档分类任务。其中，分级注意力用于建模分层语义结构，同时考虑文档中不同结构（标题和摘要）之间的语义，结构中不同句子、句子中不同单词之间的语义。Huang et al.^[35] 采用分级注意力机制提取同构图中不同类型的公司关

系，有选择性地收集相邻节点的不同关系信息，并结合股票价格的节点表示、股票新闻的节点表示来进行股票价格的趋势预测。樊海玮等学者^[13]提出了一种知识图谱和图注意力网络的引文推荐算法。首先通过嵌入层学习图谱的节点表示，再通过嵌入传播层，这一层通过图注意力网络传播节点特征，最后预测层计算推荐得分并得出候选列表。这项研究通过堆叠传播层得到不同阶的注意力相关系数，将 k 层节点的特征表示建模为 $k-1$ 层节点特征表示和添加注意力的向量表示的权重。

3. 理论背景

3.1. 图神经网络

图类型的数据结构能够对节点及其关系进行建模，近年来，随着越来越多的学习任务要求建模包含丰富的关系信息的图数据，深度学习领域对图的研究也受到了更多研究者的关注。由于传统的卷积神经网络仅能处理欧式数据结构，在面对图这一非欧式数据结构时，卷积神经网络需泛化来处理操作对象大小不一致的情况。基于此, Scarselli et al.^[48]在 2009 年首次提出了 GNN，将卷积神经网络和图表示学习相结合，解决了图数据结构的学习问题，并能获得图数据的高质量嵌入表示。

3.1.1. 图的基本概念

图 G 是表示网络系统的数学模型，通常由元组 $G = (V, E, A)$ 来表示，其中， V 为节点集合， E 为边集合。 A 为邻接矩阵， $v_i \in V$ 表示其中的某个节点， $e_{ij} = (v_i, v_j) \in E$ 表示从节点 v_i 到 v_j 的边，由 A 为 $N \times N$ 的矩阵，其中，

$$A_{ij} = \begin{cases} 1, & e_{ij} \in E \\ 0, & e_{ij} \notin E \end{cases} \quad (3.1)$$

图与节点属性 X 相关联， $X \in R^{N \times D}$ 是一个特征矩阵， $X_i \in R^D$ 表示节点 v_i 的特征向量。当 $D = 1$ 时， $X \in R^N$ 表示特征向量。

拉普拉斯矩阵是用来研究图结构性质的核心对象，可以被用来描述中心节点与相邻节点的信号关系。拉普拉斯矩阵 L 的定义为： $L = D - A$ 。 D 为特征矩阵，

A 为邻接矩阵。拉普拉斯矩阵的元素级别定义如下：

$$L_{ij} = \begin{cases} \deg(v_i) & i = j \\ -1 & e_{ij} \in E \\ 0 & \text{其他} \end{cases} \quad (3.2)$$

此外，拉普拉斯矩阵还有一种正则化的形式： $L_{\text{sym}} = D^{-1/2}LD^{-1/2}$ ，其元素级别的定义为：

$$L_{\text{sym}}[i, j] = \begin{cases} 1 & i = j \\ -1/\sqrt{\deg(v_i)\deg(v_j)} & e_{ij} \in E \\ 0 & \text{其他} \end{cases} \quad (3.3)$$

假设图 G 的拉普拉斯矩阵为 $sL \in R^{N \times N}$ ，由于 L 是一个实对称矩阵，根据实对称矩阵都可以被正交对角化的特性，可得：

$$L = U\Lambda U^T = \begin{bmatrix} \vdots & \vdots & \cdots & \vdots \\ u_1 & u_2 & \cdots & u_N \\ \vdots & \vdots & \cdots & \vdots \end{bmatrix} \begin{bmatrix} \lambda_1 & & & \\ & \lambda_2 & & \\ & & \lambda_3 & \\ & & & \lambda_4 \end{bmatrix} \begin{bmatrix} \cdots & u_1 & \cdots \\ \cdots & u_2 & \cdots \\ \cdots & \vdots & \cdots \\ \cdots & u_N & \cdots \end{bmatrix} \quad (3.4)$$

其中， $U \in R^{N \times N}$ 是一个正交矩阵，即 $UU^T = I$ ， $U = [u_1, u_2, \dots, u_N]$ 表示 L 的 N 个特征向量， λ_k 表示第 k 个特征向量对应的特征值。

3.1.2. 图卷积网络 (Graph Convolution Networks, GCN)

图卷积网络 (GCN)^[37] 是第一个将卷积神经网络 (CNN) 应用于处理图结构数据的工作，与 CNN 从图像中提取最重要的信息以对图像进行分类的方式类似，GCN 也在图上传递过滤器，搜索可用于对图中节点进行分类的重要顶点和边。GCN 的核心思想是在图中生成节点或链接的唯一欧几里得表示，传统上，基于谱域的方法使用特征分解生成节点表示向量，但计算效率低下且不可推广。GCN 通过其强大的近似能力克服了上述挑战，其中在 $l+1$ 层的节点表示向量 $H^{(l+1)}$ 更新方程可定义如下：

$$H^{(l+1)} = \sigma(\tilde{D}^{-\frac{1}{2}}\tilde{A}\tilde{D}^{-\frac{1}{2}}H^{(l)}W^{(l)}) \quad (3.5)$$




图 3-1 多层图卷积网络 (GCN) 示意图

其中, $\tilde{A} = A + I_N$ 是添加了自连接的无向图 G 的邻接矩阵。 I_N 是单位矩阵, $\tilde{D}_{ii} = \sum_j \tilde{A}_{ij}$ 和 $W^{(l)}$ 是可训练的权重矩阵, $\sigma(\cdot)$ 表示激活函数, 如果激活函数为 $ReLU$, 则有 $ReLU(\cdot) = \max(0, \cdot)$ 。

图3-1是用于半监督学习的多层图卷积网络 (GCN) 的示意图, 其中输入有 C 个通道, 输出层中有 F 个特征图。图结构 (边显示为黑线) 跨层共享, 标签用 Y_i 表示。

对于图上的谱域卷积, 可以定义为信号 $x \in \mathbb{R}^N$ 与滤波器 $g_\theta = \text{diag}(\theta)$ 相乘的结果, 定义如下:

$$g_\theta \star x = U g_\theta U^\top x \quad (3.6)$$

其中, U 是归一化的图拉普拉斯矩阵 $L = I_N - D^{-\frac{1}{2}} A D^{\frac{1}{2}} = U \Lambda U^\top$ 的特征向量矩阵, 其特征值 Λ 和 $U^\top x$ 的对角矩阵是图的傅里叶变换, g_θ 可以理解为 L 的特征值的函数, 即 $g_\theta(\Lambda)$ 。由于特征向量矩阵 U 的乘法的计算复杂度为 $O(N^2)$, 等式3.6的计算开销是比较大的, 此外, 对于大型图来说, 计算 L 的特征分解就已经会消耗大量的计算资源。为了解决这个问题, Hammond et al.^[31]提可以通过切比雪夫多项式 $T_k(x)$ 的 K 阶阶段来很好的近似 $g_\theta(\Lambda)$:

$$g_{\theta'}(\Lambda) \approx \sum_{k=0}^K \theta'_k T_k(\tilde{\Lambda}) \quad (3.7)$$

其中, $\tilde{\Lambda}$ 是被缩放的 Λ , $\tilde{\Lambda} = \frac{2}{\lambda_{max}} L - I_N$, λ_{max} 表示 L 的最大特征值, $\theta' \in \mathbb{R}^K$ 是切比雪夫系数向量。切比雪夫的递归多项式可定义为 $T_K(x) = 2xT_{K-1}(x) - T_{K-2}(x)$, 其中, $T_0(x) = 1$ $T_1(x) = x$ 。

回到对谱域卷积的定义，则有如下等式：

$$g_{\theta'} \star x \approx \sum_{k=0}^K \theta'_k T_k(\tilde{L})x \quad (3.8)$$

由 $(U\Lambda U^\top)^k = U\Lambda^k U^\top$ ，可知，上式中的 $\tilde{L} = \frac{2}{\lambda_{max}}L - I_N$ 。注意，式 **g-theta-new** 是拉普拉斯的 K 阶多项式，因此，这个表达式现在是 K 阶局部的，即它仅依赖于中心节点 K 阶邻域内的节点。式 **g-theta-new** 的计算复杂度为 $O(|\epsilon|)$ ，即图中边的数量是线性的。Defferrard et al.^[24]在图上定义的卷积神经网络便使用了这种局部卷积。

3.1.3. GraphSAGE

GraphSAGE 是一种节点归纳的嵌入方法，利用节点的属性来学习嵌入函数^[30]，它支持同时学习拓扑结构以及节点特征在受限邻域内的分布。该方法训练了一个可以识别节点邻域的结构属性的神经网络，从而指示其在图中的局部特征以及全局位置。首先，该算法对图形结构数据中每个节点的局部邻域中的节点特征进行采样，然后网络会学习一个映射，以聚合每个节点在 GNN 层传播时接收的消息。这种归纳学习方法可以在不同大小的图以及给定的子图上扩展。GraphSAGE 算法的核心是学习一个为每个节点产生嵌入的映射，而不是试图学习一个图上所有节点的嵌入。

具体来说，GraphSAGE 算法不是对每个节点都训练一个单独的嵌入向量，而是训练了一组聚合函数，这些函数学习如何从一个节点的局部邻居聚合特征信息（如图 1）。每个聚合函数从一个节点的不同的 hops 或者说不同的搜索深度聚合信息。测试或是推断的时候，使用训练好的系统，通过学习到的聚合函数来对完全未见过的节点生成嵌入。

GraphSAGE 中的嵌入生成或者前向传播算法伪代码如 Algorithm 1 所示，该算法假设模型已经过训练并且参数是固定的。具体来说，该算法假设我们已经学习了 K 个聚合函数的参数（表示为 $\text{AGGREGATE}_k, \forall k \in \{1, \dots, K\}$ ），它聚合了来自节点邻居的信息，以及一组权重矩阵 $\mathbf{W}^k, \forall k \in \{1, \dots, K\}$ ，用于在模型的不同层或“搜索深度”之间传播信息。




图 3-2 GraphSAGE 采样方法和聚合过程的可视化描述。

Algorithm 1 GraphSAGE embedding generation (i.e., forward propagation) algorithm

Input: Graph $\mathcal{G}(\mathcal{V}, \mathcal{E})$; input features $\{\mathbf{x}_v, \forall v \in \mathcal{V}\}$; depth weight matrices $\mathbf{W}^k, \forall k \in \{1, 2, \dots, K\}$; non-linearity σ ; differentiable aggregator functions $\text{AGGREGATE}_k, \forall k \in \{1, 2, \dots, K\}$; neighborhood function $\mathcal{N} : v \rightarrow 2^{\mathcal{V}}$

Output: Vector representations $\mathbf{z}_v$ for all $v \in \mathcal{V}$

- 1: $\mathbf{h}_v^0 \leftarrow \mathbf{x}_v, \forall v \in \mathcal{V}$
 - 2: **for** $k = 1 \dots K$ **do**
 - 3: **for** $v \in \mathcal{V}$ **do**
 - 4: $\mathbf{h}_{\mathcal{N}(v)}^k \leftarrow \text{AGGREGATE}_k(\{\mathbf{h}_u^{k-1}, \forall u \in \mathcal{N}(v)\})$
 - 5: $\mathbf{h}_v^k \leftarrow \sigma(\mathbf{W}^k \cdot \text{CONCAT}(\mathbf{h}_v^{k-1}, \mathbf{h}_{\mathcal{N}(v)}^k))$
 - 6: **end for**
 - 7: $\mathbf{z}_v \leftarrow \mathbf{h}_v^K, \forall v \in \mathcal{V}$
 - 8: **end for**
 - 9: $\mathbf{h}_v^0 \leftarrow \mathbf{x}_v, \forall v \in \mathcal{V} = 0$
-

Algorithm 1背后的思想是，在每次迭代或搜索深处，节点从其本地邻居聚合信息，并且随着此过程的迭代，节点逐渐从图的更远范围获得越来越多的信息。

Algorithm 1描述了在整个图 $\mathcal{G}(\mathcal{V}, \mathcal{E})$ 和所有节点 $\mathbf{x}_v, \forall v \in \mathcal{V}$ 的特征作为输入的情况下的嵌入生成过程。接下来将描述如何将其推广到小批量的设置。Algorithm 1 外循环中的每一步按如下进行，其中 k 表示外循环（或搜索深度）中的当前步骤， $\mathbf{h}^k$ 表这一步的节点表示：首先，每个节点 $v \in \mathcal{V}$ 聚合将其直接邻域中的节点

$\{\mathbf{h}_u^{k-1}, \forall u \in \mathcal{N}(v)\}$ 表示为单个向量 $\mathbf{h}_{\mathcal{N}(v)}^{k-1}$ 。请注意，此聚合步骤取决于在外循环的前一次迭代中生成的表示（即 $k-1$ ），并且 $k=0$ 的节点表示被定义为输入的节点特征。聚合相邻特征向量后，GraphSAGE 将当前的节点表示 $\mathbf{h}_v^{k-1}$ 和聚合之后的邻居节点表示向量 $\mathbf{h}_{\mathcal{N}(v)}^{k-1}$ 进行串联，这个串联向量通过具有非线性激活函数 σ 的全连接层，串联向量经过该全连接层的转换，用于算法的下一步计算（即 $\mathbf{h}_v^k, \forall v \in \mathcal{V}$ ）。为了符号方便，我们将深度 K 处的最终表示输出表示为 $\mathbf{z}_v \equiv \mathbf{h}_v^K, \forall v \in \mathcal{V}$ 。邻居节点表示的聚合可以通过各种聚合器架构来完成（由 Algorithm 1 中的 AGGREGATE 占位表示）。本文将在接下来的部分介绍 GraphSAGE 算法中使用的聚合方法。

为了将 Algorithm 1 扩展到小批量设置，给定一组输入节点，我们首先对所需的邻域集进行前向采样（直到深度 K ），然后运行内部循环（Algorithm 1 中的第 3 行），但不是迭代所有节点，只需计算满足每个深度递归所需的表示。

为了在完全无监督的环境中学习有用的预测表示，Algorithm 1 将基于图的损失函数应用于输出表示 $\mathbf{z}_u, \forall u \in \mathcal{V}$ ，并通过随机梯度下降调整权重矩阵 $\mathbf{W}^k, \forall k \in \{1, \dots, K\}$ 和聚合器函数的参数。基于图的损失函数鼓励附近的节点具有相似的表示，同时强制不同节点具有高度不同的表示。

$$J_{\mathcal{G}}(\mathbf{z}_u) = -\log(\sigma(\mathbf{z}_u^\top \mathbf{z}_v)) - Q \cdot \mathbb{E}_{v_n \sim P_n(v)} \log(\sigma(-\mathbf{z}_u^\top \mathbf{z}_{v_n})) \quad (3.9)$$

其中， v 是在固定长度随机游走中在 u 附近共现的节点， σ 是 sigmoid 激活函数， P_n 是负采样分布， Q 定义了负样本的数量。重要的是，与以前的嵌入方法不同，输入此损失函数的表示 $\mathbf{z}_u$ 是从节点局部邻域中包含的特征生成的，而不是为每个节点训练唯一的嵌入。

这种无监督设置模拟了节点特征作为服务或静态存储库提供给下游机器学习应用程序的情况。在表示仅用于特定下游任务的情况下，无监督损失（等式 3.9）可以简单地由任务特定目标（例如，交叉熵损失）代替或增强。

最后，对于 GraphSAGE 算法中使用的聚合方法，由于节点的邻居没有自然排序；因此，算法 1 中的聚合函数必须在一组无序的向量上运行。理想情况下，聚合函数将是对称的（即，对其输入的排列不变），可训练的，以及具有较高的表示能力。聚合函数的对称性确保了神经网络模型可以被训练并应用于任意有序的节点邻域特征集。GraphSAGE 有三个候选聚合函数：

- 均值聚合：第一个候选聚合函数是均值算子，其中简单地取 $\{\mathbf{h}_u^{k-1}, \forall u \in \mathcal{N}(v)\}$ 中向量的元素均值。平均聚合几乎等同于 GCN 框架中使用的卷积传播规则^[37]。特别地，我们可以通过用以下内容替换算法1中的第 4 行和第 5 行来导出 GCN 方法的归纳变体：

$$\mathbf{h}_v^k \leftarrow \sigma(\mathbf{W} \cdot \text{MEAN}(\{\mathbf{h}_v^{k-1}\} \cup \{\mathbf{h}_u^{k-1}, \forall u \in \mathcal{N}(v)\})) \quad (3.10)$$

在 GraphSAGE 中，将这种改进的基于均值的聚合称为卷积，因为它是局部谱卷积^[37]的粗略线性近似。该卷积聚合与 GraphSAGE 中提出的其他聚合器之间的一个重要区别是，它不执行算法 1 第 5 行中的串联操作，即卷积聚合器将节点的前一层表示 $\mathbf{h}_v^{k-1}$ 与聚合邻域向量 $\mathbf{h}_{\mathcal{N}(v)}^k$ 串联。这种连接可以被视为 GraphSAGE 算法的不同“搜索深度”或“层”之间的一种简单的“跳过连接”^[32]，它可以显著提高性能。

- LSTM 聚合：基于 LSTM 架构的聚合器^[29]是更复杂的，与平均聚合器相比，LSTM 具有更大表达能力的优势。然而，需要注意的是，LSTM 本质不是对称的（即它们不是转置不变的），因为它们以顺序的方式处理输入。通过简单地将 LSTM 应用于节点邻居的随机排列，使 LSTM 可适应于在无序集合上操作。
- 池聚合：池聚合器既是对称的又是可训练的。在这种池化方法中，每个邻居的向量都独立地通过一个全连接的神经网络提供；在此转换之后，应用元素最大池化操作来聚合邻居节点的信息：

$$\text{AGGREGATE}_k^{\text{pool}} = \max\left(\left\{\sigma\left(\mathbf{W}_{\text{pool}} \mathbf{h}_{u_i}^k + \mathbf{b}\right), \forall u_i \in \mathcal{N}(v)\right\}\right), \quad (3.11)$$

其中， $\max$ 表示元素最大运算符， σ 是非线性激活函数。原则上，在最大池之前应用的函数可以是任意深度的多层感知机，但 GraphSAGE 在这项工作中专注于简单的单层架构。这种方法的灵感来自应用神经网络架构学习一般点集的最新进展^[46]。直观地，多层感知器可以被认为是一组函数，用于计算相邻集合中每个节点的特征表示。通过将最大池算子应用于每个计算的特征，该模型有效地捕捉了邻域集的不同方面。还要注意，原则上，任何对称向量函数都可以用来代替 $\max$ 运算符（例如，逐元素均值）。

3.1.4. 图注意力网络 (Graph Attention Networks)

图注意力网络假设相邻节点对目标节点的贡献既不像 GCN 那样预先确定，也不像 GraphSage 那样完全相同，GAT 采用注意力机制来学习两个连接节点之间的相对权重，对于单个图注意层。输入是节点特征的集合， $h = \{\vec{h}_1, \vec{h}_2, \dots, \vec{h}_N\}$ ， $\vec{h}_i \in \mathbb{R}^F$ ，其中 N 为节点数量， F 是每个节点的特征的数量，该图注意力层的输出是一组新的节点特征， $h' = \{\vec{h}'_1, \vec{h}'_2, \dots, \vec{h}'_N\}$ ， $\vec{h}'_i \in \mathbb{R}^{F'}$ 。

为了使模型获得足够的表达能力，以将输入特征转换为更高层次的特征，至少需要一个可学习的线性变换。因此，首先对每个节点应用共享线性变换，该变换由权重矩阵 $\mathbf{W} \in \mathbb{R}^{F' \times F}$ 参数化，然后，对每个节点采用 self-attention 机制（一种共享的注意力机制 $a : \mathbb{R}^{F'} \times \mathbb{R}^{F'} \rightarrow \mathbb{R}$ ），来计算注意力系数：

$$e_{ij} = a(\mathbf{W}\vec{h}_i, \mathbf{W}\vec{h}_j) \quad (3.12)$$

上式代表了节点 j 的特征对节点 i 的重要性，在一般情况下，该模型允许将每一个节点纳入到其他节点的计算中，而忽略了图的结构信息。在 GAT 网络中，仅计算节点 $j \in \mathcal{N}_i$ 的 e_{ij} ，其中 $\mathcal{N}_i$ 是节点 i 的某个邻域。为了使系数在不同的节点之间易于比较，使用 *softmax* 函数在 j 的维度上进行归一化：

$$\alpha_{ij} = \text{softmax}_j(e_{ij}) = \frac{\exp(e_{ij})}{\sum_{k \in \mathcal{N}_i} \exp(e_{ik})} \quad (3.13)$$

使用单层前馈神经网络 a 来表示注意力机制，并由权重向量 $\vec{\mathbf{a}} \in \mathbb{R}^{2F'}$ 进行参数化，并采用 LeakyReLU 作为非线性激活函数，完全展开后，由注意力机制（如图3-3所示）计算的系数可以表示为：

$$\alpha_{ij} = \frac{\exp(\text{LeakyReLU}(\vec{\mathbf{a}}^T [\mathbf{W}\vec{h}_i || \mathbf{W}\vec{h}_j]))}{\sum_{k \in \mathcal{N}_i} \exp(\text{LeakyReLU}(\vec{\mathbf{a}}^T [\mathbf{W}\vec{h}_i || \mathbf{W}\vec{h}_k]))} \quad (3.14)$$

其中， $\cdot^T$ 表示转置， $||$ 表示串联操作。

之后，归一化的注意力系数用于计算其对应的特征的线性组合，以作为每个节点的最终输出特征：

$$\vec{h}'_i = \sigma\left(\sum_{j \in \mathcal{N}_i} \alpha_{ij} \mathbf{W}\vec{h}_j\right) \quad (3.15)$$




图 3-3 GAT 模型中应用的注意力机制 $a(\mathbf{W}\vec{h}_i, \mathbf{W}\vec{h}_j)$ ，通过权重向量 $\vec{a} \in \mathbb{R}^{2F'}$ 参数化，并应用 LeakyReLU 的激活函数

为了使 self-attention 的学习过程更加稳定，可以将该机制扩展到多头注意力。具体来说， K 个独立的注意力机制执行了公式3.15的变换，然后将它们的特征连接起来，产生如下的特征表示：

$$\vec{h}'_i = \parallel_{k=1}^K \sigma \left(\sum_{j \in \mathcal{N}_i} \alpha_{ij}^k \mathbf{W}^k \vec{h}_j \right) \quad (3.16)$$

其中， $\parallel$ 表示串联操作， α_{ij}^k 是第 k 个注意力机制 a^k 计算的归一化注意力系数， $\mathbf{W}^k$ 是相应的输入变换的线性矩阵。

如果在网络的预测层使用多头注意力机制，串联的操作将不再适用，求平均的操作会更适合于此种场景，此外，非线性的变换也将在求平均值后进行，可表示为如下等式：

$$\vec{h}'_i = \sigma \left(\frac{1}{K} \sum_{k=1}^K \sum_{j \in \mathcal{N}_i} \alpha_{ij}^k \mathbf{W}^k \vec{h}_j \right) \quad (3.17)$$

多头图注意力层的聚合操作如图3-4所示。




图 3-4 一个节点在其邻居节点上的多头注意力机制 (3 个头)。不同的箭头样式和颜色表示独立的注意力计算，将每个头的聚合特征串联或平均以获得 $\vec{h}'_1$

3.2. 深度强化学习

深度强化学习指的是采用深度神经网络技术的强化学习算法，深度神经网络的发展为强化学习提供了强大的工具，使得强化学习的发展进入了新的阶段。

3.2.1. 强化学习概述

目前机器学习 (Machine Learning) 分为三个主要领域: 强化学习 (Reinforcement Learning, RL)、监督学习 (Supervised Learning) 以及非监督学习 (Unsupervised Learning)。其中的监督学习以及非监督学习都是利用机器学习算法进行模型设计、预测目标回归以及评估等方法构建输入数据与输出数据之间的联系，与此不同的是，强化学习所应用的环境并没有确定的回归目标，而是利用算法在于环境的探索交互中，通过预先设置的反馈函数，学习在环境中最佳的决策模型。强化学习来源于基本的试错思想，通过探索尝试获取经验，加强得到正反馈的行为，减少得到负反馈的行为。它的核心在于与环境进行交互，并通过延迟回报实现整体路径的最优。强化学习的目标是在不断地尝试中迭代算法，不断获取新的知识，以此改进策略。基于强化学习的策略基本逻辑是算法智能体通过感知当前环境状态，输出当前动作，环境根据动作给予智能体即时反馈，智能体通过反馈对算法内部




图 3-5 强化学习基本框架示意图

参数进行更新迭代。因此强化学习的学习速率与环境状态空间大小、环境复杂度、动作维度关系紧密。

3.2.2. 强化学习原理

强化学习中主要包含两个主题：智能体（Agent）与环境（Environment）。其中智能体指的是算法本身或使用算法的控制系统，环境指的是与智能体进行沟通交互的元素的集合。强化学习的基本框架如图3-5所示。

在每一个时刻 t 下，智能体会观察环境并获得当前环境状态 S_t ，并根据当前环境状态进行决策，输出并执行动作 A_t ，环境接受到动作 A_t 后发生变化，给予智能体即时的反馈 R_t ，并进入下一时刻。因此从起始时刻到时刻 T ，智能体与环境的交互可以得到一个交互集合 $[S_1, A_1, R_1, S_2, A_2, R_2, \dots, S_T, A_T, R_T]$ 。强化学习建立在马尔科夫决策过程（Markov Decision Process, MDP）上，马尔科夫决策过程中要求下一时刻的状态只有当前时刻的状态决定，与之前时刻的状态无关，假设当前时刻为 t ，当前时刻的状态为 S_t ，则

$$P(S_{t+1} | S_t) = P(S_{t+1} | S_t, S_{t-1}, \dots, S_1, S_0) \quad (3.18)$$

在马尔科夫决策过程中，每一状态都可以通过一个价值判断好坏，由于未来的状态仅与当前状态有关，因此可以通过每一状态价值的累加判断整个决策过程

的好坏，假设时刻 t 下这一累加价值为 G_t ，则

$$G_t = R_t + \gamma R_{t+1} + \gamma^2 R_{t+2} + \dots = \sum_{k=0}^{\infty} \gamma^k R_{t+k} \quad (3.19)$$

其中 γ 为折扣因子 (discount factor)，通常小于 1，折扣因子表示随着时间增加，未来状态的反馈对当前状态的影响会逐渐减小，折扣因子的引入也保证了 G_t 不会因为未来时间的无限延长而趋向于无穷的情况出现。计算 G_t 需要整个过程完全结束后，获得每一个时刻下的反馈才能得到。因此强化学习中引入了价值函数，状态 s 下的价值函数的定义为：

$$\begin{aligned} V^\pi(s) &= \sum_{s' \in \mathcal{S}} p(s' | s, \pi(s)) [r(s' | s, \pi(s)) + \gamma V^\pi(s')] \\ &= E[G_t | S_t = s] \end{aligned} \quad (3.20)$$

其中 s 表示环境中某一具体状态， s' 表示下一时刻环境可能变成的状态， $\mathcal{S}$ 表示环境所有可能的状态集合， π 表示智能体在当前环境中的行为策略。用以表示每一个状态具有的价值，假设当前时刻 t 下状态 S_t 为 s ，则：

$$\begin{aligned} V^\pi(s) &= E[G_t | S_t = s] \\ &= E[R_t + \gamma R_{t+1} + \gamma^2 R_{t+2} + \dots | S_t = s] \\ &= E[R_t + \gamma (R_{t+1} + \gamma R_{t+2} + \dots) | S_t = s] \\ &= E[R_t + \gamma G_{t+1} | S_t = s] \\ &= E[R_t + \gamma V^\pi(S_{t+1}) | S_t = s] \end{aligned} \quad (3.21)$$

从上式中可以看出，对于 t 时刻下为 s 的状态 S_t 而言，状态 s 的价值与当前获得的即时反馈 R_t 以及下一时刻的状态 S_{t+1} 有关，这也是贝尔曼方程 (Bellman Equation) 的基本形式。

在强化学习中，策略的更新表现在智能体动作的输出上，因此对于动作价值的判断更为重要，即输出每一个状态下价值更高的动作。因此强化学习中引入了动作价值函数，用以表示每一个状态下，每一个可执行动作所具有的价值，假设时刻 t 下 S_t 的状态为 s ，可执行的动作为 a ，则：

$$\begin{aligned} Q^\pi(s, a) &= \sum_{s' \in \mathcal{S}} p(s' | s, a) [r(s' | s, a) + \gamma V^\pi(s')] \\ &= E[G_t | S_t = s, A_t = a] \end{aligned} \quad (3.22)$$

因此，动作价值函数对应的贝尔曼方程为：

$$Q^\pi(s, a) = E[R_t + \gamma Q^\pi(S_{t+1}, A_{t+1}) | S_t = s, A_t = a] \quad (3.23)$$

对于智能体而言，策略优化的目标为使得每一个状态价值或每一个动作价值最优，即：

$$\begin{aligned} V^*(s) &= \max_{\pi} V^\pi(s) \\ Q^*(s, a) &= \max_{\pi} Q^\pi(s, a) \end{aligned} \quad (3.24)$$

利用贝尔曼方程，上式可以推导得到：

$$\begin{aligned} V^*(s) &= \max_{a \in \mathcal{A}} \left(\sum_{s' \in \mathcal{S}} p(s' | s, a) [r(s' | s, a) + \gamma V^\pi(s')] \right) \\ Q^*(s, a) &= \max_{a \in \mathcal{A}} \left(\sum_{s' \in \mathcal{S}} p(s' | s, a) [r(s' | s, a) + \gamma Q^\pi(S_{t+1}, A_{t+1})] \right) \end{aligned} \quad (3.25)$$

在智能体与环境的迭代中，将动作价值函数迭代直至收敛，之后智能体选择每一状态下最优的动作进行输出，即为当前环境下的最优策略，迭代过程如下：

$$Q^{k+1}(s, a) = \max_{a \in \mathcal{A}} \left(\sum_{s' \in \mathcal{S}} p(s' | s, a) [r(s' | s, a) + \gamma Q^k(S_{t+1}, A_{t+1})] \right) \quad (3.26)$$

其中 k 表示迭代次数。

根据不同的迭代方法，强化学习逐渐延伸出了 MC (Monte-Carlo)、SARSA (State-Action-Reward-State-Action)、Q-learning 等多种方法。

3.2.3. 深度强化学习

深度神经网络的出现，提高了机器学习模型的特征提取能力，为强化学习提供了强大的模型工具。2013 年，DeepMind 首次将深度学习与强化学习结合，提出了深度 Q 网络算法 (Deep Q Network, DQN) [34]，算法利用深度神经网络替换了 Q-learning 中的 Q 表部分，同时利用双层 Q 网络稳定了算法的更新过程。2014 年，Silver et al. 将 DPG (Deterministic Policy Gradient) 与深度学习算法相结合，提出了 DDPG 算法 (Deep Deterministic Policy Gradient) [35]，DDPG 算法利用四个深度神经网络解决了连续动作空间下的强化学习问题。2015 年，Schulman et al. 提出了 TRPO 算法 [36]，通过引入约束项，加速了 Policy Gradient 算法的收敛速度。2017 年 7 月，DeepMind 和 OpenAI 提出了 PPO 算法 (Proximal Policy Optimization) [37]，

PPO 算法通过重要性采样 (Importance sampling) 方法将 Policy Gradient 算法中的 On-policy 训练转化为 Off-policy，同时利用 CLIP 方法修改了 TRPO 中 KL 散度对智能体更新参数的限制，简化了限制条件的同时，提高了算法的训练速度，更能适合维度空间较大的大规模运算场景。

3.2.4. PPO 算法

PPO (Proximal Policy Optimization) 算法基于 Actor-Critic 架构，利用裁剪代理目标简化了 TRPO (Trust Region Policy Optimization) 算法，降低了算法实现难度的同时保证了算法的收敛性能与准确性。

Actor-Critic 算法中，Actor 部分的参数更新公式如下所示，其中 θ 表示 Actor 网络参数， α 表示学习率， $\nabla\theta$ 为梯度。选取合适的学习率对于参数的更新至关重要。若学习率过小，则容易出现参数收敛过慢，同时有可能出现局部收敛的情况；若学习率过大，则容易出现参数波动较大，甚至出现无法收敛的情况。

$$\theta = \theta + \alpha \nabla\theta \quad (3.27)$$

TRPO 算法采用了新旧策略之间距离来确定学习率。即更新参数后的策略不应该距离旧策略过远，同时更新后的策略需要提升效果，参数更新公式如下所示。

$$\begin{aligned} & \max_{\theta} E_{s \sim \pi_{\theta_{old}}, a \sim \pi_{\theta_{old}}} \left[\frac{\pi_{\theta}(a|s)}{\pi_{\theta_{old}}(a|s)} A_{\theta_{old}}(s, a) \right] \\ & \text{subject to } E_{s \sim \pi_{\theta_{old}}} \left[KL \left(\pi_{\theta_{old}}(\cdot | s), \pi_{\theta}(\cdot | s) \right) \right] \leq \delta \\ & A_{\theta}(s, a) = Q_{\theta}(s, a) - V_{\theta}(s) \end{aligned} \quad (3.28)$$

其中， $A_{\theta}(s, a)$ 表示优势函数，即在状态 s 下，动作 a 相对于其他所有动作的平均价值之差，优势函数大于 0，说明动作 a 优于平均动作，反之，说明动作 a 差于平均动作。KL 散度 (KL-divergence) 也称为相对熵 (relative entropy)，用以衡量两个概率分布之间的不同程度。TRPO 通过 KL 散度的限制，限定了新策略与旧策略之间的差异，使得更新后的策略不会过于发散，若忽略 KL 散度的限制，则会出现训练波动较大，出现难以收敛的情况。在满足策略更新距离的情况下，若旧策略优势函数大于零，则需要使这部分优势最大的继承下来，相反，若旧策略优势函数小于 0，则需要使这部分的劣势最大的回避掉。

PPO 算法将旧策略与新策略的动作概率之比定义为 $r(\theta)$ ，则原目标函数可以改写为：

$$\begin{aligned} r(\theta) &= \frac{\pi_{\theta}(a|s)}{\pi_{\theta_{old}}(a|s)} \\ J &= E_{s \sim \pi_{\theta_{old}}, a \sim \pi_{\theta_{old}}} [r(\theta) A_{\theta_{old}}(s, a)] \end{aligned} \quad (3.29)$$

PPO 策略将 KL 散度的限制转化为裁剪限制，公式如下。PPO 算法将新旧策略的动作概率比值 $r(\theta)$ 限制在 $[1 - \epsilon, 1 + \epsilon]$ 之间，保证了新策略与旧策略之比稳定在 1 附近。

$$\begin{aligned} L^{CLIP}(\theta) &= \hat{E}_t [\min(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t)] \\ \hat{A}_t &= A_{\theta_{old}}(s, a) \Big|_{S_t=s, A_t=a} \\ \hat{E}_t[\cdot] &= E_{s \sim \pi_{\theta_{old}}, a \sim \pi_{\theta_{old}}} [\cdot] \end{aligned} \quad (3.30)$$

裁剪策略保证了策略参数更新在一定范围内，提升输出优质动作的概率。若旧策略的优势函数大于 0，即此时选择的动作优于平均动作，策略的更新容易出现加大选择当前动作的概率，导致 $r(\theta)$ 大于 1，此时裁剪限制将 $r(\theta)$ 的最大值设定为 $1 + \epsilon$ ，保证了新策略不会过激的提高当前动作的概率；相反的，若旧策略的优势函数小于 0，即此时选择的动作差于平均动作，策略的更新容易出现降低选择当前动作的概率，导致 $r(\theta)$ 小于 1，此时裁剪限制将 $r(\theta)$ 的最小值设定为 $1 - \epsilon$ ，保证了新策略不会过激的降低当前动作的概率。

同时 PPO 策略也可以利用 KL 散度进行限制，公式如下：

$$L^{KL PEN}(\theta) = \hat{E}_t [r_t(\theta) \hat{A}_t - \beta KL(\pi_{\theta_{old}}(\cdot | s), \pi_{\theta}(\cdot | s))] \quad (3.31)$$

这里直接将 KL 散度作为惩罚项加入限制， β 表示 KL 散度的惩罚系数， β 也可以通过新旧策略之间的距离进行调整，调整方法如下：

$$\begin{aligned} \beta &= \begin{cases} 0.5\beta & \text{if } d < d_{\text{targ}} / 1.5 \\ 2\beta & \text{if } d > d_{\text{targ}} \times 1.5 \end{cases} \\ d &= \hat{E}_t [KL(\pi_{\theta_{old}}(\cdot | s), \pi_{\theta}(\cdot | s))] \end{aligned} \quad (3.32)$$

d 表示新旧策略之间的距离，若 d 过小，表示新旧策略之间的距离很小，此时说明策略更新较为保守，则可以减小 KL 散度对策略更新的惩罚项 β ，让策略更新激进一些，反之，若 d 过大，表示新旧策略之间的距离很大，此时说明策略更新较为激进，则可以增大 KL 散度对策略更新的惩罚项 β ，让策略更新保守一些。

仅考虑裁剪限制的情况下，PPO 算法最终的目标函数包含三个部分：裁减目标函数、价值函数均方误差以及策略模型动作概率分布的熵，如下所示：

$$L^{CLIP+VF+S}(\theta) = \hat{E}_t [L_t^{CLIP}(\theta) - c_1 L_t^{VF}(\theta) + c_2 S[\pi_\theta](S_t)] \quad (3.33)$$

其中 $L_t^{CLIP}(\theta)$ 表示裁剪目标，用来对照旧策略更新参数，同时限制参数更新范围， $L_t^{VF}(\theta)$ 表示价值函数的均方误差，由 Critic 部分求得，表示当前策略下发的动作价值与目标价值之间的误差， $S[\pi_\theta](S_t)$ 表示当前状态策略下动作概率分布的熵，这一项将提升策略的更新范围，意在提高策略的探索能力。 c_1 ， c_2 为超参数，分别表示价值函数均方误差以及动作概率熵的权重。

PPO 算法框架逻辑如 Algorithm2所示，算法通过裁减目标函数、价值函数均方误差以及策略模型动作概率分布熵三重目标，既保证了 Actor 网络向最优策略更新，又限制了更新策略不会出现激进更新的情况，同时保留了智能体尝试探索的优势。极大的提高了算法的收敛速度与收敛能力。其中 K 表示训练次数， L 表示目标函数， N 表示 Actor 个数。

Algorithm 2 PPO

```

1: Initialize  $\theta$ 
2:  $\theta_{old} \leftarrow \theta$ 
3: for  $iteration = 1, 2, \dots, N$  do
4:   for  $actor = 1, 2, \dots, N$  do
5:     Run policy  $\theta_{old}$  in environment for  $T$  timesteps
6:     Compute Advantage estimates  $A_1, A_2, \dots, A_T$ 
7:   end for
8:   Optimize surrogate  $L$  w.r.t  $\theta$ , with  $K$  epochs and minibatch size  $M < NT$ 
9:    $\theta_{old} \leftarrow \theta$ 
10: end for

```

4. 模型构建

4.1. 模型整体框架

本文提出了一种新的融资成本预测框架，利用上市公司过去三年的融资成本数据，结合上市公司产品竞争关系，预测上市公司未来 1-3 年的融资成本，该框架由竞品关系补全和融资成本预测两个子任务构成。首先，我们通过企业年报数据，初步提炼企业产品竞争关系网络，由于年报数据具有不完整性，提取出的竞品关系网络也会存在信息缺失，因此，我们采用强化学习方法建模链路预测任务，对竞品关系网络中可能缺失的链路进行补全；第二个子任务是利用补全的竞品关系网络，将历史融资成本数据作为节点特征，进行未来年度的融资成本的预测，在该子任务中，我们在图神经网络种引入了分级注意力机制，对直接竞争关系的企业和间接竞争关系的企业给予不同的注意力，这种分级注意力机制能有效嵌入到不同的图神经网络结构中，如 GCN、GraphSAGE 等。

4.2. 竞品关系补全

由于企业年报数据往往存在信息不完整的情况，本研究中从企业年报中提取的竞品关系也是不完整的，因此，对提取的竞品关系网络进行补全，是一项必要的任务。

在本研究中，采用强化学习中的 PPO 算法来完成对竞品关系的补全，通过迭代进行链路预测，最后可生成一个拥有较为完整的关系的竞品关系网络。我们将该问题建模为一个马尔可夫决策过程 $M = (\mathcal{S}, \mathcal{A}, P, R, \gamma)$ 。其中， $\mathcal{S} = \{s_i\}$ 是包含所有中间过程的竞品关系网络以及最终的竞品关系网络； $\mathcal{A} = \{a_i\}$ 描述在当前时间步对当前的竞品关系网络所做的修改操作； P 是状态转移函数，描述了在当前状态下执行指定动作之后，下一步的状态可能会变成什么样， $p(s_{t+1} | s_t, \dots s_0, a_t)$ ；

$R(s_t)$ 是奖励函数, 描述达到状态 s_t 后, 所获得的奖励; γ 是折扣因子。竞品关系网络补全的过程可以用轨迹 $(s_0, a_0, r_0, \dots, s_n, a_n, r_n)$ 来描述, 其中, s_n 代表了关系得到补全后的最终的竞品关系网络。每个时间步中对图的修改可以看作是状态转移分布, $p(s_{t+1} | s_t, \dots, s_0) = \sum_{a_t} p(a_t | s_t, \dots, s_0) p(s_{t+1} | s_t, \dots, s_0, a_t)$, 其中 $p(a_t | s_t, \dots, s_0)$ 通常表示为策略网络 π_θ 。

接下来, 我们将详细讨论竞品关系网络补全任务中的 MDP 建模过程:

我们将 t 时刻的环境状态 s_t 定义为中间过程的竞品关系网络图 G^t , 该状态可被强化学习的智能体完全观测到, s_0 代表初始的竞品关系网络。在本研究中, 通过两层 GraphSAGE 网络计算的节点嵌入来编码当前时刻的竞品关系网络结构以及节点特征, 表示如下:

$$\mathbf{S}_t = \mathbf{h}_v^k, \forall v \in \mathcal{V} \quad (4.1)$$

$$\mathbf{h}_v^k = \sigma(\mathbf{W}^k \cdot \text{CONCAT}(\mathbf{h}_v^{k-1}, \mathbf{h}_{\mathcal{N}(v)}^k)) \quad (4.2)$$

$$\mathbf{h}_{\mathcal{N}(v)}^k = \text{AGGREGATE}_k(\{\mathbf{h}_u^{k-1}, \forall u \in \mathcal{N}(v)\}) \quad (4.3)$$

其中, $\mathbf{h}_v^k$ 为节点 v 在第 k 层的节点嵌入, 由上一层的节点嵌入 $\mathbf{h}_v^{k-1}$ 和 $\mathbf{h}_{\mathcal{N}(v)}^k$ 做 CONCAT 操作得到 (式4.2), σ 为激活函数, $\mathbf{h}_{\mathcal{N}(v)}^k$ 由上一层的邻居节点嵌入做聚合操作得到 (式4.3)。

智能体观测到当前环境的状态后, 根据当前状态计算输出动作, 决定何处添加新的链接。在设计动作空间时, 为了使新添加的链接更合理并减小动作空间, 我们仅允许强化学习在同行业的公司之间添加新的链接。此外, 我们设计了一个类似滑动窗口的动作选择范围, 每个时间步, 让智能体在一定数目的节点对中做决策, 保证在一次迭代的所有时间步中, 遍历完图中所有无链接的节点对, 算法将针对每一个节点对, 输出其存在链接的概率。在时间 t 时的动作空间可表示为:

$$A_t = (A_t^1, A_t^2, \dots, A_t^{N_{node_pair}}) \quad (4.4)$$

其中, N_{node_pair} 为单个时间步中, 强化学习输出动作的节点对数目。

在 t 时刻算法输出动作后, 环境将在一段时间后收到算法动作的影响并计算动作所获得的奖励。我们使用 t 时刻的竞品关系网络进行融资成本的预测, 并将

测试集的均方根误差 RMSE 纳入奖励函数的计算中，RMSE 的定义如下：

$$RMSE = \sqrt{\frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2} \quad (4.5)$$

其中， m 为样本总数， y_i 和 $\hat{y}_i$ 分别为第 i 个样本数据的真实值和预测值。

奖励函数的定义如下：

$$R_t = \begin{cases} e^{(RMSE_0 - RMSE_t)} & RMSE_0 > RMSE_t \\ \alpha(RMSE_0 - RMSE_t) & RMSE_0 \leq RMSE_t \end{cases} \quad (4.6)$$

其中， α 大于 0 的参数， $RMSE_0$ 为使用初始竞品关系网络计算的 RMSE， $RMSE_t$ 为使用 t 时刻生成的竞品关系网络计算的 RMSE，奖励函数的计算公式确保了算法在不断迭代的过程中，通过不断提升过程的累计价值，从而使得动作输出倾向于使测试集的 RMSE 越来越小。

在竞品关系补全的 MDP 中，目标是最大化整体奖励，目标公式为：

$$\max_{\pi} \sum_{i=0}^{\infty} \gamma^i R_{t+i} \quad (4.7)$$

其中， γ 表示折扣因子，用以减小未来奖励的同时确保算法收敛， π 表示算法策略，对于采用神经网络为基础的强化学习算法，在这种复杂系统中可以通过多次训练迭代来计算出最优策略。

综上所述，采用强化学习的竞品关系网络补全算法的整体架构如图4-1 所示，算法智能体获得当前环境提供的状态信息 $\mathbf{S}_t$ （当前竞品关系网络的节点嵌入）之后，算法将根据状态信息输出动作，动作为一定数目的节点对中存在链接的概率，环境将在执行动作后将奖励与下一时刻的环境状态反馈给算法智能体，算法智能体获得奖励后，将保存整个过程的状态、动作、奖励、经验，用以迭代算法参数。

4.3. 融资成本预测模型

4.3.1. 问题定义

在本研究中，我们以竞品关系为视角，进行融资成本的预测，由于竞品关系为非欧数据，因此，我们采用图神经网络的方法来进行融资成本的预测。在该问




图 4-1 竞品关系补全算法强化学习架构

题中，给定竞品关系网络图 $G = (V, E, A)$ ，其中 V 是 N 个上市公司节点， E 是公司之间的边，两个公司节点之间有边则说明两个公司之间存在竞争关系，该关系通过邻接矩阵 A 表示。 $\mathbf{X} \in R^{N \times D}$ 表示特征矩阵， $X_i \in R^D$ 表示某一个公司的特征向量，在本研究中，每个公司的特征向量由该公司过去三年的融资成本组成，即 $D = 3$ 。融资成本预测问题可以表示为：给定竞品关系网络 $G = (V, E, A)$ 和历史的融资成本数据 $X_i = (x_1, x_2, x_3) \ i = 1, 2, \dots, N$ ，旨在建立 3 个预测模型，接收历史融资成本数据，能够分别预测出未来 1-3 年的融资成本。

4.3.2. 模型架构

在企业的产品竞争关系网络中，若公司 A 与公司 B 存在链接，公司 B 与公司 C 之间存在链接，而公司 A 与公司 C 之间不存在链接，则认为公司 A 与公司 B 存在直接竞争关系，公司 A 与公司 C 存在间接竞争关系，显然公司 B 和公司 C 对公司 A 的融资成本的影响是不同的，因此，我们在图神经网络模型中引入分级注意力机制来建模这种直接间接的竞争关系。

考虑两层的 GraphSAGE 模型，对于第 k 层的节点表示，首先对其邻居节点的嵌入进行聚合：

$$\mathbf{h}_{\mathcal{N}(v)}^k = \text{AGGREGATE}_k(\{\mathbf{h}_u^{k-1}, \forall u \in \mathcal{N}(v)\}) \quad (4.8)$$

其中， $\mathbf{h}_u^{k-1}$ 为节点 v 的邻居节点在第 $k-1$ 层的节点嵌入，随后，计算第 k 层的注

注意力系数,

$$e_1^k = a(\mathbf{h}_v^k, \mathbf{h}_v^{k-1}), e_2^k = a(\mathbf{h}_v^k, \mathbf{h}_{\mathcal{N}(v)}^k) \quad (4.9)$$

上式中, a 代表注意力机制,

为了使系数在不同的节点之间易于比较, 使用 *softmax* 函数对注意力系数归一化, 归一化后的注意力系数可表示为:

$$\alpha_j^k = \text{softmax}(e_j^k) = \frac{\exp(e_j^k)}{\sum_{j=1}^2 \exp(e_j^k)} \quad (4.10)$$

对节点 v 在第 k 层的节点嵌入应用注意力机制, 可表示为:

$$\mathbf{h}_v^k = \sigma(\alpha_1^k \mathbf{W}_1^k \mathbf{h}_v^{k-1} + \alpha_2^k \mathbf{W}_2^k \mathbf{h}_{\mathcal{N}(v)}^k) \quad (4.11)$$

4.3.3. 损失函数

损失函数在模型训练过程中也起到了至关重要的作用。常见的损失函数有交叉熵损失函数和均方差损失函数。交叉熵损失函数适用于分类问题, 均方差损失函数适用于回归问题。考虑到本文的融资成本预测是多元回归问题, 因此选取均方差 (Mean SquaredError, MSE) 损失函数, 计算方法为:

$$MSE = \frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2 \quad (4.12)$$

其中, m 为预测结果个数, y_i 为真实值, $\hat{y}_i$ 为预测值。

4.3.4. 评价指标

为评估模型预测结果, 本文选取了三种回归任务常见评价指标, 分别为均方根误差 RMSE、平均绝对值误差 MAE、平均绝对百分比误差 MAPE。各评价指标计算方法如下所示:

(1) 均方根误差 RMSE

RMSE 可以用来评价预测结果和真实数据间的变化程度, RMSE 的数值越小, 说明通过计算所得的预测模型对于实验数据描述的准确度越高。RMSE 定义为:

$$RMSE = \sqrt{\frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2} \quad (4.13)$$

(2) 平均绝对误差 MAE

MAE 是指算术平均值与所有单个观测值的偏差取绝对值后的均值。MAE 值越小，代表预测精度越高。MAE 的定义为：

$$MAE = \frac{1}{m} \sum_{i=1}^m |(y_i - \hat{y}_i)| \quad (4.14)$$

(3) 平均绝对百分比误差 MAPE

MAPE 用来刻画预测值和真实值之间的平均偏离程度。MAPE 值越小，代表预测精度越高。MAPE 的定义为：

$$MAPE = \frac{1}{m} \sum_{i=1}^m \frac{|(y_i - \hat{y}_i)| \bullet 100\%}{\hat{y}_i} \quad (4.15)$$

(4) 决定系数 R^2

决定系数是回归平方与总平方和之比，可以反应模型拟合程度，表示预测值对真实值的代表程度。范围为 0 ~ 1，值越接近于 1 表示结果越好， R^2 的定义为：

$$R^2 = \frac{\sum_{i=1}^m (y_i - \bar{y}_i)^2 - \sum_{i=1}^m (y_i - \hat{y}_i)^2}{\sum_{i=1}^m (y_i - \hat{y}_i)^2}. \quad (4.16)$$

上面四个公式中， m 为样本总数， y_i 和 $\hat{y}_i$ 分别问第 i 个样本数据的真实值和预测值。

5. 实验设计及结果分析

5.1. 数据集

本文以中国 A 股上市公司的数据作为研究对象，首先，根据年报中企业的经营范围、经营产品，提炼了企业的产品竞争关系，并建立竞争关系的邻接矩阵。随后，我们选取了 2010 年-2021 年企业的财务数据来完成对企业融资成本的预测。对于融资成本的计算，已有研究也有多种计算方法，准确地衡量融资成本是比较困难的，在此，我们借鉴了李广子等学者^[12]和魏志华等学者^[18]的做法，采用企业财务费用占期末总负债的比重来考察，定义如下：

$$Cost_t = \frac{\text{财务费用}_t}{\text{期末总负债}_t} \quad (5.1)$$

上式中， $Cost_t$ 代表第 t 期的债务融资成本，第 t 期的财务费用和第 t 期的期末总负债可在上市公司披露的财务报表中获取，“财务费用”包括“利息支出”、“利息收入”、“手续费”、“其他财务费用”和“汇兑损益”五项明细科目，我们通过加总“利息支出”、“手续费”和“其他财务费用”作为企业净财务费用的近似，以此来反映企业当期所发生的与债务融资有关的总的成本。此外，由于不同年份中，很多企业存在某些财务数据缺失的情况，为了扩充数据，我们将不同年份级的数据合并，一起放入模型进行训练，表5-1展示了模型的具体数据变量，其中， $Model_1$ ， $Model_2$ ， $Model_3$ 分别代表对未来 1 年、2 年、3 年的融资成本进行预测的模型， $Cost_{2010}$ 代表某公司 2010 年的融资成本，本模型的输入变量均为过去三年的融资成本。在合并数据后，共得到 13412 条可用数据，按训练集：验证集：测试集 = 8：1：1 的比例进行划分后，送入模型进行训练。

表 5-1 模型数据变量

预测模型	输入变量	预测变量	总数据条数
$Model_1$	$Cost_{2010}, Cost_{2011}, Cost_{2012}$	$Cost_{2013}$	13412
	$Cost_{2011}, Cost_{2012}, Cost_{2013}$	$Cost_{2014}$	
	$Cost_{2012}, Cost_{2013}, Cost_{2014}$	$Cost_{2015}$	
	$Cost_{2013}, Cost_{2014}, Cost_{2015}$	$Cost_{2016}$	
	$Cost_{2014}, Cost_{2015}, Cost_{2016}$	$Cost_{2017}$	
	$Cost_{2015}, Cost_{2016}, Cost_{2017}$	$Cost_{2018}$	
	$Cost_{2016}, Cost_{2017}, Cost_{2018}$	$Cost_{2019}$	
$Model_2$	$Cost_{2010}, Cost_{2011}, Cost_{2012}$	$Cost_{2014}$	13412
	$Cost_{2011}, Cost_{2012}, Cost_{2013}$	$Cost_{2015}$	
	$Cost_{2012}, Cost_{2013}, Cost_{2014}$	$Cost_{2016}$	
	$Cost_{2013}, Cost_{2014}, Cost_{2015}$	$Cost_{2017}$	
	$Cost_{2014}, Cost_{2015}, Cost_{2016}$	$Cost_{2018}$	
	$Cost_{2015}, Cost_{2016}, Cost_{2017}$	$Cost_{2019}$	
	$Cost_{2016}, Cost_{2017}, Cost_{2018}$	$Cost_{2020}$	
$Model_3$	$Cost_{2010}, Cost_{2011}, Cost_{2012}$	$Cost_{2015}$	13412
	$Cost_{2011}, Cost_{2012}, Cost_{2013}$	$Cost_{2016}$	
	$Cost_{2012}, Cost_{2013}, Cost_{2014}$	$Cost_{2017}$	
	$Cost_{2013}, Cost_{2014}, Cost_{2015}$	$Cost_{2018}$	
	$Cost_{2014}, Cost_{2015}, Cost_{2016}$	$Cost_{2019}$	
	$Cost_{2015}, Cost_{2016}, Cost_{2017}$	$Cost_{2020}$	
	$Cost_{2016}, Cost_{2017}, Cost_{2018}$	$Cost_{2021}$	




图 5-1 PPO 算法训练过程奖励函数值

5.2. 竞品关系补全

我们采用强化学习中的 PPO 算法来进行企业竞品关系的补全，计算奖励函数所需的测试集 RMSE，是使用加入分级注意力机制的 GraphSAGE 模型预测未来一年期的融资成本，训练 100 个 epoch 得出的。在进行竞品关系补全算法之前，初始的 RMSE 值为 0.0149，补全竞争关系之后，最优的 RMSE 值是 0.0067，较初始 RMSE 降低了 0.0082，降低了 55.03%，这说明我们所提出的竞品关系补全算法是非常有效的。我们还分析了 PPO 算法在训练过程中的表现，图5-1、图5-2分别为训练过程中的奖励函数值和 RMSE 的曲线图。从结果来看，PPO 算法在 30 次迭代时，即可获得较好的迭代收敛效果，此时较初始的 RMSE 值已经有了 0.0075 的降低幅度，降低的百分比为 50%。在后面的 70 次迭代中，也能够根据已有的经验进一步稳定的提升性能，这也说明了 PPO 算法的稳定性。

5.3. 融资成本预测

在这一小节，我们与一系列基准方法进行了对比，并将我们提出的分级注意力机制加入到 GCN、GAT、GraphSAGE 等模型中，通过对比在融资成本预测任务上的效果，验证了所提出的分级注意力机制的有效性，此外，为了进一步验证所提出的竞品关系补全算法的有效性，我们还针对竞品关系补全进行了消融实验。




图 5-2 PPO 算法训练过程值

5.3.1. 结果分析

表5-2、表5-3、表5-4分别显示了对未来一年、二年、三年的融资成本预测模型的各项指标结果。我们首先分析未来一年的融资成本预测，即表5-2中的结果，从表中数据不难发现，首先，在基准模型上，GraphSAGE 模型的表现最优，这应该是由于在竞品关系网络中，具有了大量的公司节点，而 GraphSAGE 是适用于大型图的归纳表示学习方法，因此能够很好的适应竞品关系网络这一大型图上的学习任务，其次是 GCN 模型的表现较好，GAT 模型的表现是最差的，这可能是由于 GAT 模型在计算注意力机制时，使用了节点属性信息来计算邻居节点重要性，并没有使用到图谱最重要的结构信息，导致 GAT 模型在聚合二阶邻居时，效果会骤然下降。第二，我们观察到，在 GraphSAGE、GCN、GAT 这三种模型的基础上应用本研究所提出的分级注意力机制之后，模型的效果都会有提示，仅有 GAT 模型在施加分级注意力机制后，MAPE 指标的值略有上升（由 5.1897 变为 5.7089），其余模型各指标的结果均是更优的。这也说明了我们所提出的分级注意力机制在各基准模型中都能够具有较好的适用性。

在预测未来二、三年的融资成本中，也同样是 GraphSAGE 模型优于 GCN 模型，且优于 GAT 模型，与预测未来一年的融资成本模型得出的结论基本一致。在预测未来二年的融资成本时，加了分级注意力机制的 GraphSAGE 模型在 MAPE 指标上的表现劣于无分级注意力机制的 GraphSAGE 模型，其余指标也是均由于无分

表 5-2 未来一年融资成本预测模型

模型	RMSE	MAE	MAPE	R^2
GCN	0.0416	0.0163	3.4572	0.3946
GCN+ 分级 Attention	0.0349	0.0148	3.6784	0.5081
GAT	0.0438	0.0180	5.1897	0.2291
GAT+ 分级 Attention	0.0393	0.0179	5.7089	0.3751
GraphSAGE	0.0117	0.0056	1.2097	0.8619
GraphSAGE+ 分级 Attention	0.0067	0.0027	0.5626	0.9553

表 5-3 未来二年融资成本预测模型

模型	RMSE	MAE	MAPE	R^2
GCN	0.0231	0.0148	3.2040	0.3018
GCN+ 分级 Attention	0.0209	0.0115	2.7637	0.4266
GAT	0.0412	0.0173	3.388	0.1213
GAT+ 分级 Attention	0.0377	0.0168	3.0793	0.2621
GraphSAGE	0.0209	0.0112	2.7835	0.4240
GraphSAGE+ 分级 Attention	0.0205	0.0108	3.2885	0.4490

级注意力机制的模型。但是，在预测未来三年的融资成本时，加入分级注意力机制的模型表现较为不稳定，首先，对于 GCN 模型而言，加入注意力机制之后，仅有 MAE 和 MAPE 两个指标的结果得到改善，对于 GAT 模型，MAE 指标的结果在加入分级注意力机制之后并未得到改善，对于 GraphSAGE 模型。加入分级注意力机制后，MAPE 和 R^2 指标的值均未得到改善。我们猜测这可能是由于在预测未来三年期的融资成本时，由于时间与现在相隔较远，使得当前的产品竞争关系对未来三年的融资成本的影响减弱，从而使得分级注意力机制对产品竞争关系的提取也相对减弱。

表 5-4 未来三年融资成本预测模型

模型	RMSE	MAE	MAPE	R^2
GCN	0.0265	0.0142	3.0285	0.2929
GCN+ 分级 Attention	0.0268	0.0123	2.3823	0.2818
GAT	0.0278	0.0154	2.9060	0.2251
GAT+ 分级 Attention	0.0292	0.0153	3.0655	0.1418
GraphSAGE	0.0191	0.0115	2.933	0.4339
GraphSAGE+ 分级 Attention	0.0208	0.0109	3.0830	0.3797

5.3.2. 消融实验

我们使用效果最好的 GraphSAGE+ 分级 Attention 模型分别进行了消融实验，利用未补全的竞品关系网络，和补全之后的竞品关系网络，分别对未来 1-3 年的融资成本进行预测，以验证所提出的竞品关系补全算法的有效性。表5-5显示了消融实验的结果。由表中数据可知，利用补全后的竞品关系网络图预测未来一、二、三的融资成本，其指标都能高于未补全的竞品关系网络，消融实验的结果也进一步说明了我们所提出的竞品关系补全算法在实际预测中的有效性。

表 5-5 消融实验结果

	是否补图	RMSE	MAE	MAPE	R^2
未来一年融资成本预测	未补图	0.0149	0.0062	1.3413	0.7737
	补图后	0.0067	0.0027	0.5626	0.9553
未来二年融资成本预测	未补图	0.0220	0.0133	3.4567	0.3687
	补图后	0.0205	0.0108	3.2885	0.4490
未来三年融资成本预测	未补图	0.0207	0.0124	3.1782	0.3354
	补图后	0.0208	0.0109	3.0830	0.3797

6. 总结与展望

本文以企业产品竞争关系为视角，对融资成本进行研究，提出了一种新的融资成本预测框架，该框架由竞品关系补全和融资成本预测两个子任务组成。

首先，我们通过上市公司年报中的数据，初步提炼企业产品竞争关系网络，由于企业披露的年报数据具有不完整性，因此我们提取出的竞品关系网络也会存在信息缺失。因此，为了建立关系更完善的竞品关系网络，我们采用强化学习方法建模链路预测任务，对竞品关系网络中可能缺失的链路进行预测；第二个子任务是利用补全的竞品关系网络，将历史融资成本数据作为节点特征，进行未来 1-3 年的融资成本的预测，在该子任务中，我们在图神经网络中引入了分级注意力机制，对直接竞争关系的企业和间接竞争关系的企业给予不同的注意力，这种分级注意力机制能有效嵌入到不同的图神经网络结构中，如 GCN、GraphSAGE 等。

通过实验，我们发现，采用强化学习方法，能够有效补全网络中缺失的链路，构建关系更加完善的网络，且能够有效提升下一阶段对融资成本预测的效果；此外，在各类经典的图神经网络模型中，GraphSAGE 模型的性能最佳，且在引入本文所提出的分级注意力机制后，能够有显著的效果提升，这也说明了本研究提出的分级注意力机制的有效性。

最后，尽管本文提出的融资成本预测框架在预测性能上显示了良好的优势，可以让企业管理者预知，在当前不变的竞争关系下，未来 1-3 年的融资成本，以方便企业管理者制定或调整未来年度的股权、债务融资结构，或者在预测到融资成本过高时，做出相应的市场战略调整。但是，本文提出的预测框架并不能让企业管理者知道，在调整了融资结构或者市场战略之后，融资成本会怎么变。因此，在实际应用探索方面，还有待提升。

参考文献

- [1] 万国超, 张渝, 朱琳. 股价崩盘风险会影响债务融资成本吗? [J]. 财会通讯, 2023, No.912(04): 72-75. DOI: 10.16144/j.cnki.issn1002-8072.2023.04.006.
- [2] 伊志宏, 姜付秀, 秦义虎. 产品市场竞争, 公司治理与信息披露质量[J]. 管理世界, 2010(1): 133-141.
- [3] 冯熠. ESG 发展对证券公司债务融资的影响探讨[J]. 中国货币市场, 2023(62-66).
- [4] 刘中华, 王心悦, 曹瑜强. 司法改善与企业债务融资——基于巡回法庭设立准自然实验的经验证据[J]. 财会月刊,
- [5] 刘凤委, 李琦. 市场竞争, EVA 评价与企业过度投资[J]. 会计研究, 2013(2): 54-62.
- [6] 刘梦莎, 邵淇, 阮青松. 数字化转型对企业债务融资成本的影响研究[J]. 财经问题研究, 2023, No.470(01): 63-72.
- [7] 向志容, 李栋, 李业嘉. LPR 机制改革对企业债务融资成本的影响及异质性分析——基于非国有上市公司的经验实证[J]. 黑龙江金融, 2022, No.527(12): 21-26.
- [8] 姜付秀, 黄磊, 张敏. 产品市场竞争, 公司治理与代理成本[J]. 世界经济, 2009(10): 46-59.
- [9] 戴书松, 涂莹. 产品市场势力, 市场竞争与债券融资成本[J]. 会计之友, 2020(18): 20-25.
- [10] 施静. 零售企业产品竞争, 战略差异与债务融资成本[J]. 商业经济研究, 2020, No.810(23): 117-120.

- [11] 朱武祥, 陈寒梅, 吴迅. 产品市场竞争与财务保守行为——以燕京啤酒为例的分析[J]. 经济研究, 2002(8): 28-36.
- [12] 李广子, 刘力. 债务融资成本与民营信贷歧视[J]. 金融研究, 2009(12): 137-150.
- [13] 樊海玮, 鲁芯丝雨, 张丽苗, 等. 融合知识图谱和图注意力网络的引文推荐算法[J]. 计算机应用, 2023: 1-8.
- [14] 王俊^①, 魏梦蝶, 徐玉姝. 卖空制度对企业融资的影响研究——基于融券卖空制度的检验[J]. 财经理论与实践, 2023, 44: 34-41. DOI: 10.16339/j.cnki.hdxbcj.2023.01.005.
- [15] 王文, 孙早, 牛泽东. 产业政策, 市场竞争与资源错配[J]. 经济学家, 2014, 9(9): 22-32.
- [16] 石磊, 张迪, 刘柯含. ESG 表现对企业境外债券融资的影响[J]. 财会月刊, 2023, 44(03): 41-48.
- [17] 罗莉苹. 多个大股东对债务融资成本治理的影响机制研究[J]. 财会通讯, 2023, No.911: 69-72. DOI: 10.16144/j.cnki.issn1002-8072.2023.03.024.
- [18] 魏志华, 王贞洁, 吴育辉, 等. 金融生态环境, 审计意见与债务融资成本[J]. 审计研究, 2012(3): 98-105.
- [19] 黄政. 高管持股对企业债务融资成本的影响[D]. 浙江大学, 2022.
- [20] 黎来芳, 叶宇航, 孙健. 市场竞争, 负债融资与过度投资[J]. 中国软科学, 2013(11): 91-100.
- [21] CHEN Y, WEI Z, HUANG X. Incorporating corporation relationship via graph convolutional neural networks for stock price prediction[C]//Proceedings of the 27th ACM International Conference on Information and Knowledge Management. 2018: 1655-1658.
- [22] CLAUSET A, MOORE C, NEWMAN M E. Hierarchical structure and the prediction of missing links in networks[J]. Nature, 2008, 453(7191): 98-101.
- [23] DAVIDSON T R, FALORSI L, DE CAO N, et al. Hyperspherical variational auto-encoders[J]. arXiv preprint arXiv:1804.00891, 2018.

- [24] DEFFERRARD M, BRESSON X, VANDERGHEYNST P. Convolutional neural networks on graphs with fast localized spectral filtering[J]. Advances in neural information processing systems, 2016, 29.
- [25] DO K, TRAN T, VENKATESH S. Graph Transformation Policy Network for Chemical Reaction Prediction[J]., 2019: 750-760. DOI: 10.1145/3292500.3330958.
- [26] FENG F, HE X, WANG X, et al. Temporal relational ranking for stock prediction [J]. ACM Transactions on Information Systems (TOIS), 2019, 37(2): 1-30.
- [27] GIGANTE G, MANGLAVITI D. The ESG effect on the cost of debt financing: A sharp RD analysis[J]. International Review of Financial Analysis, 2022, 84: 102382.
- [28] GIRVAN M, NEWMAN M E. Community structure in social and biological networks[J]. Proceedings of the national academy of sciences, 2002, 99(12): 7821-7826.
- [29] GRAVES A, GRAVES A. Long short-term memory[J]. Supervised sequence labelling with recurrent neural networks, 2012: 37-45.
- [30] HAMILTON W, YING Z, LESKOVEC J. Inductive representation learning on large graphs[J]. Advances in neural information processing systems, 2017, 30.
- [31] HAMMOND D K, VANDERGHEYNST P, GRIBONVAL R. Wavelets on graphs via spectral graph theory[J]. Applied and Computational Harmonic Analysis, 2011, 30(2): 129-150.
- [32] HE K, ZHANG X, REN S, et al. Identity mappings in deep residual networks[C] //Computer Vision–ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part IV 14. 2016: 630-645.
- [33] HOLLAND P W, LASKEY K B, LEINHARDT S. Stochastic blockmodels: First steps[J]. Social networks, 1983, 5(2): 109-137.

- [34] HU B, ZHANG Z, SHI C, et al. Cash-out user detection based on attributed heterogeneous information network with a hierarchical attention mechanism[C]// Proceedings of the AAAI Conference on Artificial Intelligence: vol. 33: 01. 2019: 946-953.
- [35] HUANG K, LI X, LIU F, et al. ML-GAT: A Multilevel Graph Attention Model for Stock Prediction[J]. IEEE Access, 2022, 10: 86408-86422.
- [36] ITOH T D, KUBO T, IKEDA K. Multi-level attention pooling for graph neural networks: Unifying graph representations with multiple localities[J]. Neural Networks, 2022, 145: 356-373.
- [37] KIPF T N, WELING M. Semi-supervised classification with graph convolutional networks[J]. arXiv preprint arXiv:1609.02907, 2016.
- [38] KIPF T N, WELING M. Variational graph auto-encoders[J]. arXiv preprint arXiv:1611.07308, 2016.
- [39] KREBS V E. Mapping networks of terrorist cells[J]. Connections, 2002, 24(3): 43-52.
- [40] KUDO W, NISHIGUCHI M, TORIUMI F. Gcnnext: graph convolutional network with expanded balance theory for fraudulent user detection[J]. Social Network Analysis and Mining, 2020, 10: 1-12.
- [41] LI P, WANG Y, WANG H, et al. Distance Encoding: Design Provably More Powerful Neural Networks for Graph Representation Learning[C/OL]// LAROCHELLE H, RANZATO M, HADSELL R, et al. Advances in Neural Information Processing Systems 33: Annual Conference on Neural Information Processing Systems 2020, NeurIPS 2020, December 6-12, 2020, virtual. 2020. <https://proceedings.neurips.cc/paper/2020/hash/2f73168bf3656f697507752ec592c437-Abstract.html>.
- [42] LI W, BAO R, HARIMOTO K, et al. Modeling the stock relation with graph network for overnight stock movement prediction[C]//Proceedings of the twenty-

- ninth international conference on international joint conferences on artificial intelligence. 2021: 4541-4547.
- [43] LIANG T, ZENG G, ZHONG Q, et al. Credit risk and limits forecasting in e-commerce consumer lending service via multi-view-aware mixture-of-experts nets [C]//Proceedings of the 14th ACM international conference on web search and data mining. 2021: 229-237.
 - [44] LIU H, HU Z, HADDADI H, et al. Hidden link prediction based on node centrality and weak ties[J]. EPL (Europhysics letters), 2013, 101(1): 18004.
 - [45] OPLER T C, TITMAN S. Financial distress and corporate performance[J]. The Journal of finance, 1994, 49(3): 1015-1040.
 - [46] QI C R, SU H, MO K, et al. Pointnet: Deep learning on point sets for 3d classification and segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 652-660.
 - [47] RAIMO N, CARAGNANO A, ZITO M, et al. Extending the benefits of ESG disclosure: The effect on the cost of debt financing[J]. Corporate Social Responsibility and Environmental Management, 2021, 28(4): 1412-1421.
 - [48] SCARSELLI F, GORI M, TSOI A C, et al. The graph neural network model[J]. IEEE transactions on neural networks, 2008, 20(1): 61-80.
 - [49] SCHLICHTKRULL M, KIPF T N, BLOEM P, et al. Modeling relational data with graph convolutional networks[C]//European semantic web conference. 2018: 593-607.
 - [50] TELSER L G. Cutthroat competition and the long purse[J]. The Journal of Law and Economics, 1966, 9: 259-277.
 - [51] VASHISHTH S, SANYAL S, NITIN V, et al. Composition-based multi-relational graph convolutional networks[J]. arXiv preprint arXiv:1911.03082, 2019.
 - [52] WANG H, LE Z. Seven-Layer Model in Complex Networks Link Prediction: A Survey[J/OL]. Sensors, 2020, 20(22): 6560. <https://doi.org/10.3390/s20226560>.

DOI: 10.3390/s20226560.

- [53] WANG X, VINEL A. Benchmarking Graph Neural Networks on Link Prediction [J/OL]. CoRR, 2021, abs/2102.12557. arXiv: 2102.12557. <https://arxiv.org/abs/2102.12557>.
- [54] YANG S, ZHANG Z, ZHOU J, et al. Financial risk analysis for SMEs with graph-based supply chain mining[C] // Proceedings of the Twenty-Ninth International Conference on International Joint Conferences on Artificial Intelligence. 2021: 4661-4667.
- [55] YAO J J, QI Y A, GUO B. Corporate social responsibility, debt financing cost and enterprise innovation[J]. Scientific Reports, 2022, 12(1): 21909.
- [56] YOU J, LIU B, YING Z, et al. Graph convolutional policy network for goal-directed molecular graph generation[J]. Advances in neural information processing systems, 2018, 31.
- [57] ZHANG M, CHEN Y. Weisfeiler-lehman neural machine for link prediction[C] // Proceedings of the 23rd ACM SIGKDD international conference on knowledge discovery and data mining. 2017: 575-583.
- [58] ZHANG M, CHEN Y. Link prediction based on graph neural networks[J]. Advances in neural information processing systems, 2018, 31.
- [59] ZHANG M, CUI Z, NEUMANN M, et al. An end-to-end deep learning architecture for graph classification[C] // Proceedings of the AAAI conference on artificial intelligence: vol. 32: 1. 2018.
- [60] ZHANG M, LI P, XIA Y, et al. Revisiting Graph Neural Networks for Link Prediction[J/OL]. CoRR, 2020, abs/2010.16103. arXiv: 2010.16103. <https://arxiv.org/abs/2010.16103>.
- [61] ZHAO W, FANG D, ZHANG J, et al. An effective framework for semistructured document classification via hierarchical attention model[J/OL]. Int. J. Intell. Syst., 2021, 36(9): 5161-5183. <https://doi.org/10.1002/int.22508>. DOI: 10.1002/int.225

08.

- [62] ZHOU T, LÜ L, ZHANG Y C. Predicting missing links via local information[J].
The European Physical Journal B, 2009, 71(4): 623-630.

7. 致谢

